

Univerzitet u Beogradu

Matematički fakultet

Analiza ćelijskog sastava ljudske jetre primenom single-cell RNA-seq metode

Projekat iz predmeta Istraživanje podataka 2

Milica Zubljic 47/2022

Natalija Pavličević 68/2022

Jun 2026.

Sadržaj

1	Uvod	4
1.1	Ljudska jetra i ćelijski sastav	4
1.2	Single-cell RNA-seq tehnologija	4
1.3	Cilj rada	4
2	Opis skupa podataka	5
2.1	Dataset sa genskom ekspresijom	5
2.2	Dataset sa oznakama ćelija	5
3	Pretprocesiranje podataka	5
3.1	Opšti koraci pretprocesiranja	5
3.1.1	Uklanjanje neinformativnih gena	5
3.1.2	Ograničavanje ekstremnih vrednosti (Outlier Clipping)	6
3.1.3	Transponovanje matrice	6
3.2	Priprema podataka za klasifikaciju	7
3.2.1	Spajanje tabela	7
3.2.2	Definisanje atributa i ciljne promenljive	7
3.2.3	Kodiranje ciljne promenljive	8
3.2.4	Podela na trening i test skup	9
3.2.5	Standardizacija ulaznih podataka	9
3.3	Priprema podataka za pravila pridruživanja	9
3.3.1	Binarizacija	9
3.3.2	Uklanjanje previše čestih/retnih gena	10
4	Metodologija klasifikacije	10
4.1	Random Forest	11
4.2	Gradient Boosting	11
4.3	XGBoost	11
4.4	Logistička regresija	12
4.5	Support Vector Machine (SVM)	12
5	Rezultati klasifikacije	12
5.1	Random Forest	13
5.2	Gradient Boosting	13
5.3	XGBoost	14
5.4	Logistička regresija	15

5.5	Support Vector Machine (SVM)	15
6	Poređenje modela klasifikacije	16
7	Analiza značajnosti gena	17
7.1	Random Forest	18
7.2	Gradient Boosting	18
7.3	XGBoost	19
8	Vizualizacija rezultata primenom PCA	20
9	Analiza pravila pridruživanja	21
9.1	Apriori	22
9.1.1	Generisanje pravila pridruživanja	23
9.2	FP-Growth	24
9.2.1	Generisanje pravila pridruživanja za ćelijski tip Inflammatory_Macrophage	24
9.3	Pokušaj predikcije tipa ćelije pomoću pravila pridruživanja	26
9.4	CHARM	26
10	Zaključak	27

1 Uvod

1.1 Ljudska jetra i ćelijski sastav

Jetra je ključni organ u ljudskom telu. Ona služi kao centralni metabolički koordinator sa širokim spektrom esencijalnih funkcija, uključujući regulaciju metabolizma glukoze i lipida, sintezu proteina i sintezu žuči. Štaviše, jetra je visceralni organ koji je sposoban za izuzetnu prirodnu regeneraciju nakon gubitka tkiva. Međutim, bolesti jetre sve češće imaju smrtni ishod, pogotovo u poslednjih nekoliko decenija. Ćelijski pejzaž jetre jedva da je istražen na nivou pojedinačnih ćelija, što ograničava naše molekularno razumevanje funkcije jetre i biologije bolesti. Nedavna pojava osetljivih metoda sekvenciranja RNK pojedinačnih ćelija (scRNA-seq) omogućava istraživanje tipova ćelija kako zdravog, tako i bolesnog tkiva.

1.2 Single-cell RNA-seq tehnologija

Sekvenciranje RNK pojedinačnih ćelija (scRNA-seq) može otkriti složene i retke ćelijske populacije, otkriti regulatorne odnose između gena i pratiti putanje različitih ćelijskih linija u razvoju.

1.3 Cilj rada

Cilj ovog rada je analiza podataka dobijenih primenom single-cell RNA sequencing tehnologije radi identifikacije i karakterizacije različitih tipova ćelija ljudske jetre. Na osnovu profila genske ekspresije izvršena je klasifikacija ćelijskih populacija primenom različitih algoritama mašinskog učenja, kao i analiza povezanosti između gena primenom metoda za pronalaženje pravila pridruživanja.

U okviru rada sprovedeno je pretprocesiranje podataka koje obuhvata uklanjanje neinformativnih gena, selekciju najznačajnijih atributa, obradu ekstremnih vrednosti i pripremu podataka za dalju analizu. Za klasifikaciju ćelijskih tipova korišćeni su algoritmi Random Forest, Gradient Boosting, XGBoost, logistička regresija i Support Vector Machine, nakon čega su njihove performanse upoređene korišćenjem odgovarajućih evaluacionih metrika.

Dodatno, izvršena je analiza značajnosti gena radi identifikacije najinformativnijih markera za razlikovanje ćelijskih populacija, kao i primena pravila

pridruživanja u cilju otkrivanja potencijalnih obrazaca i povezanosti ekspresija različitih gena.

2 Opis skupa podataka

2.1 Dataset sa genskom ekspresijom

U ovom radu korišćen je skup podataka dobijen primenom scRNA-seq tehnologije nad ćelijama ljudske jetre. Skup podataka sadrži informacije o genskoj ekspresiji na nivou pojedinačnih ćelija, pri čemu svaki red predstavlja jednu ćeliju, dok kolone predstavljaju različite gene čija je ekspresija merena.

Originalni skup podataka sastoji se od matrice genske ekspresije dimenzija 20007x8444, gde red odgovara izabranom genu, a kolona predstavlja analiziranu ćeliju. Vrednosti u matrici predstavljaju nivo ekspresije određenog gena u određenoj ćeliji. Veće vrednosti ukazuju na veću aktivnost gena, dok vrednost nula označava odsustvo detektovane ekspresije tog gena u posmatranoj ćeliji.

2.2 Dataset sa oznakama ćelija

Pored matrice genske ekspresije, korišćena je dodatna tabela sa anotacijama ćelija, koja sadrži informacije o nazivu ćelije (CellName), uzorku (Sample), identifikacionom barkodu ćelije (Cell#), pripadajućem klasteru (Cluster#) i tipu ćelije (CellType). Ova tabela predstavlja osnovu za definisanje ciljne promenljive u klasifikacionom problemu.

3 Pretprocesiranje podataka

3.1 Opšti koraci pretprocesiranja

3.1.1 Uklanjanje neinformativnih gena

U početnoj fazi pretprocesiranja izvršeno je uklanjanje gena koji ne doprinose značajno klasifikaciji ćelijskih tipova i traženju obrazaca u podacima. Single-cell RNA-seq podaci karakterišu se velikim brojem gena, pri čemu se veliki deo njih ne ekspresuje ili pokazuje veoma malu varijabilnost između

različitih ćelija. Takvi geni mogu povećati dimenzionalnost skupa podataka, uneti šum i negativno uticati na performanse različitih modela i alata.

Prvi korak predstavlja uklanjanje gena koji se pojavljuju u malom broju ćelija. Zadržani su samo geni koji su eksprimirani u najmanje 5% ćelija.

Zatim se uklanjanjaju geni sa veoma sličnim nivoom ekspresije u svim ćelijama. Zadržavanjem najvarijabilnijih gena smanjuje se broj atributa, ubrzava treniranje modela i poboljšava sposobnost algoritama da pronađu relevantne obrasce u podacima.

Nakon ovog koraka broj atributa je smanjen sa početnog broja gena na 2000 najinformativnijih gena, čime je izvršena redukcija dimenzionalnosti uz očuvanje najvažnijih karakteristika genske ekspresije.

3.1.2 Ograničavanje ekstremnih vrednosti (Outlier Clipping)

Nakon selekcije informativnih gena izvršeno je ograničavanje ekstremnih vrednosti ekspresije gena (outlier clipping). Single-cell RNA-seq podaci mogu sadržati pojedinačne veoma visoke vrednosti ekspresije, koje nastaju usled tehničkih faktora, kao što su razlike u broju očitanih transkripata ili šum tokom merenja.

Kako bi se smanjio uticaj takvih ekstremnih vrednosti na procese klasifikacije i izdvajanja pravila pridruživanja, primenjen je clipping zasnovan na 99,9. percentilu. Vrednosti ekspresije koje prelaze definisani prag zamenjene su maksimalnom dozvoljenom vrednošću.

Ovim postupkom očuvane su informacije sadržane u distribuciji genske ekspresije, dok je istovremeno smanjen uticaj ekstremnih merenja koja bi mogla dominirati prilikom treniranja modela.

3.1.3 Transponovanje matrice

U originalnoj matrici genske ekspresije podaci su bili organizovani tako da su geni predstavljali redove, a pojedinačne ćelije kolone. Kako algoritmi za klasifikaciju zahtevaju format u kome svaki red predstavlja jedan uzorak, a svaka kolona jedan atribut, izvršeno je transponovanje matrice.

Dobijena matrica predstavlja ulazni skup atributa koji se dalje koristi u procesu klasifikacije ćelijskih tipova i izdvajanja pravila pridruživanja.

3.2 Priprema podataka za klasifikaciju

3.2.1 Spajanje tabela

Za potrebe klasifikacije bilo je neophodno objediniti informacije iz dve različite tabele. Jedna tabela sadržala je metapodatke o ćelijama, uključujući identifikator ćelije (CellName), uzorak (Sample), barkod ćelije (Cell#), klaster kojem ćelija pripada (Cluster#) i stvarni tip ćelije (CellType), dok je druga sadržala podatke o ekspresiji gena dobijene primenom single-cell RNA-seq metode, pri čemu su za svaku ćeliju zabeležene vrednosti ekspresije velikog broja gena.

Pošto obe tabele sadrže jedinstveni identifikator ćelije (CellName), izvršeno je njihovo spajanje korišćenjem ovog atributa kao zajedničkog ključa. Na taj način je za svaku ćeliju formiran jedinstven zapis koji istovremeno sadrži informacije o ekspresiji gena i odgovarajući tip ćelije.

Spajanje tabela predstavlja neophodan korak za klasifikaciju, jer se ciljna promenljiva (CellType) nalazi u tabeli sa metapodacima, dok se atributi koji služe za predikciju nalaze u tabeli ekspresije gena. Tek nakon objedinjavanja podataka moguće je formirati skup podataka pogodan za primenu algoritama klasifikacije.

3.2.2 Definisanje atributa i ciljne promenljive


Nakon spajanja tabela izvršeno je izdvajanje **ulaznih atributa (feature-a)** i **ciljne promenljive (target-a)**. Kao ciljna promenljiva izabran je atribut **CellType**, koji predstavlja stvarni tip ćelije i koji klasifikacioni modeli treba da predvide na osnovu podataka o ekspresiji gena.

Ulazne attribute činile su vrednosti ekspresije gena dobijene iz single-cell RNA-seq podataka. Svaki atribut predstavlja jedan gen, dok svaka vrsta predstavlja jednu ćeliju.

Iz skupa ulaznih atributa uklonjeni su sledeći atributi: CellName, Sample, Cell#, Cluster#, jer su oni suvišni za planiranu analizu.

Atribut Cluster# je posebno uklonjen kako bi se izbeglo curenje informacija. Pošto su klasteri formirani na osnovu obrazaca genske ekspresije, uključivanje ove informacije moglo bi veštački da poveća uspešnost klasifikacije i dovede do nerealno optimističnih rezultata.

Nakon uklanjanja navedenih atributa, skup ulaznih podataka sadržao je isključivo vrednosti ekspresije gena, dok je atribut CellType korišćen kao ciljna promenljiva za treniranje i evaluaciju klasifikacionih modela.



Slika 1: Distribucija broja ćelija po tipu

Pre treniranja klasifikacionih modela analizirana je distribucija klasa (Slika 1), odnosno zastupljenost različitih tipova ćelija u skupu podataka. Ova analiza je važna jer neuravnoteženost klasa može uticati na performanse klasifikacionih algoritama, posebno na sposobnost modela da pravilno prepozna manje zastupljene ćelijske populacije.

Na osnovu prikazane distribucije može se uočiti da skup podataka nije potpuno uniforman, odnosno da pojedini tipovi ćelija sadrže veći broj uzoraka u odnosu na druge.

Iako postoji određena razlika u broju uzoraka između klasa, sve klase sadrže dovoljan broj instanci za treniranje modela. Zbog toga nije bilo potrebno uklanjanje klasa ili dodatno balansiranje skupa podataka.

3.2.3 Kodiranje ciljne promenljive

Atribut `CellType` predstavlja kategorijsku promenljivu, odnosno sadrži tekstualne oznake različitih tipova ćelija (različite populacije ćelija prisutne u ljudskoj jetri). Pošto većina algoritama mašinskog učenja zahteva numeričku reprezentaciju ciljnih klasa, izvršeno je kodiranje ciljne promenljive. Za kodiranje je korišćena metoda **Label Encoding**, kojom je svakoj jedinstvenoj vrednosti atributa `CellType` dodeljena odgovarajuća numerička oznaka.

3.2.4 Podela na trening i test skup

Podaci su podeljeni na:

- **trening skup** – koristi se za treniranje klasifikacionih modela i učenje veza između ekspresije gena i tipa ćelije
- **test skup** – koristi se za procenu sposobnosti modela da generalizuje naučene obrasce na nove, neviđene ćelije

Prilikom podele korišćen je odnos 80:20, gde je 80% podataka iskorišćeno za trening, a 20% za testiranje modela.

Kako bi se očuvala zastupljenost svih tipova ćelija u oba skupa, primenjena je stratifikovana podela prema ciljnoj promenljivoj CellType. Na ovaj način je obezbeđeno da raspodela klasa u trening i test skupu bude približno ista kao u originalnom skupu podataka.

3.2.5 Standardizacija ulaznih podataka

Nakon podele podataka na trening i test skup izvršena je standardizacija ulaznih atributa za modele koji su osetljivi na raspon podataka (Support Vector Machine i Logistic Regression).

Podaci o ekspresiji gena mogu imati različite opsege vrednosti, zbog čega atributi sa većim numeričkim vrednostima mogu imati veći uticaj na model. Standardizacijom se svi atributi transformišu tako da imaju približno srednju vrednost 0 i standardnu devijaciju 1.

3.3 Priprema podataka za pravila pridruživanja

3.3.1 Binarizacija

Kako bi podaci bili pogodni za primenu algoritama za pravila pridruživanja, bilo je neophodno izvršiti njihovu binarizaciju. Pošto algoritmi poput Apriori i FP-Growth rade sa prikazom podataka u obliku stavki (prisutnih ili odsutnih) u transakcijama, kontinualne vrednosti genske ekspresije transformisane su u logičke vrednosti.

Za svaku ćeliju izračunat je 75. percentil ekspresije svih posmatranih gena. Gen je označen kao prisutan ukoliko njegova vrednost ekspresije u datoj ćeliji prelazi odgovarajući prag. Na taj način formirana je binarna matrica u kojoj vrednost 1 označava prisustvo gena, dok vrednost 0 označava njegovo odsustvo.

3.3.2 Uklanjanje previše čestih/retkih gena

Nakon binarizacije izvršeno je filtriranje gena na osnovu podrške. Uklonjeni su geni koji se pojavljuju u manje od 6% ćelija, kao i geni prisutni u više od 90% ćelija. Takvi geni uglavnom dovode do trivijalnih ili neinformativnih pravila i povećavaju prostor pretrage, bez značajnog doprinosa analizi.

Od 2000 gena odabranih u opštem pretprocesiranju, 552 gena uklonjena su zbog veoma male podrške, dok su 64 gena uklonjena zbog izrazito velike podrške. Nakon filtriranja zadržano je 1384 gena pogodnih za dalju analizu.

4 Metodologija klasifikacije

Nakon završene obrade podataka primenjeni su različiti klasifikacioni algoritmi sa ciljem predviđanja tipa ćelije (CellType) na osnovu obrazaca genske ekspresije dobijenih single-cell RNA-seq metodom.

Korišćeni su sledeći modeli:

- Random Forest,
- Gradient Boosting,
- XGBoost,
- Logistička regresija,
- Support Vector Machine (SVM).

Prva tri modela pripadaju metodama zasnovanim na stablima odlučivanja, dok SVM i Logistička regresija predstavljaju modele koji se zasnivaju na pronalaženju granica između klasa u prostoru atributa.

Izbor više različitih algoritama omogućava procenu koji pristup najuspešnije prepoznaje različite tipove ćelija na osnovu njihovih profila ekspresije gena. Ovo je posebno značajno kod single-cell RNA-seq podataka, gde postoji veliki broj atributa (gena), kompleksni obrasci ekspresije i potencijalno nelinearne razlike između ćelijskih populacija.

Performanse svakog modela ocenjene su korišćenjem odgovarajućih metrika klasifikacije, nakon čega je izvršeno poređenje dobijenih rezultata.

4.1 Random Forest

Random Forest predstavlja ensemble klasifikacioni algoritam zasnovan na kombinaciji većeg broja stabala odlučivanja. Umesto korišćenja samo jednog stabla, Random Forest formira veliki broj nezavisnih stabala koja se treniraju na različitim podskupovima podataka i atributa. Konačna odluka o klasi donosi se glasanjem svih pojedinačnih stabala, pri čemu se za klasifikaciju bira klasa sa najvećim brojem glasova.

Glavna prednost ovog pristupa je smanjenje preprilagođavanja u odnosu na pojedinačna stabla odlučivanja, kao i sposobnost modela da pronađe kompleksne i nelinearne odnose između ulaznih atributa i ciljne promenljive.

4.2 Gradient Boosting

Gradient Boosting predstavlja ensemble algoritam zasnovan na kombinaciji više slabijih modela, najčešće stabala odlučivanja, koji se grade sekvencijalno. Za razliku od Random Forest algoritma, gde se stabla treniraju nezavisno i njihova predviđanja se kombinuju glasanjem, kod Gradient Boosting pristupa svako novo stablo pokušava da ispravi greške prethodno izgrađenih stabala.

Za razliku od algoritama koji se zasnivaju na merenju udaljenosti između podataka, Gradient Boosting ne zahteva standardizaciju ulaznih atributa. Zbog toga je model treniran na originalnim vrednostima genske ekspresije nakon prethodno izvršenog odabira atributa i podele podataka na trening i test skup.

4.3 XGBoost

XGBoost (Extreme Gradient Boosting) predstavlja unapređenu verziju Gradient Boosting algoritma koja je zasnovana na sekvencijalnom građenju stabala odlučivanja.

Glavna razlika u odnosu na klasični Gradient Boosting jeste u dodatnim tehnikama regularizacije i optimizacije koje XGBoost koristi kako bi smanjio rizik od preprilagođavanja i poboljšao generalizaciju modela.

Kao i ostali algoritmi zasnovani na stablima odlučivanja, XGBoost ne zahteva standardizaciju ulaznih atributa, pa je treniran na originalnim vrednostima genske ekspresije nakon izvršenog odabira atributa i podele podataka na trening i test skup.

4.4 Logistička regresija

Logistička regresija predstavlja jedan od najčešće korišćenih algoritama za klasifikaciju i koristi se za predviđanje pripadnosti uzorka određenoj klasi na osnovu ulaznih atributa. Iako u nazivu sadrži reč „regresija”, ovaj algoritam se koristi za klasifikacione probleme tako što modeluje verovatnoću pripadnosti različitim klasama.

Za razliku od algoritama zasnovanih na stablima odlučivanja, logistička regresija zahteva skaliranje ulaznih atributa. Zbog toga je pre treniranja modela primenjena standardizacija atributa korišćenjem `StandardScaler` metode.

4.5 Support Vector Machine (SVM)

Support Vector Machine (SVM) predstavlja nadgledani algoritam mašinskog učenja koji se koristi za klasifikaciju podataka pronalaženjem optimalne granice razdvajanja između različitih klasa. Osnovna ideja algoritma jeste pronalaženje hiperravni koja maksimalizuje marginu između najbližih uzoraka različitih klasa, čime se postiže dobra sposobnost generalizacije na novim podacima.

SVM je osetljiv na raspon vrednosti atributa, zbog čega je pre treniranja izvršena standardizacija ulaznih atributa korišćenjem `StandardScaler` metode.

5 Rezultati klasifikacije

Nakon treniranja svakog klasifikatora izvršena je evaluacija modela na test skupu podataka. Cilj evaluacije bio je da se proceni uspešnost modela u predviđanju tipova ćelija na osnovu profila genske ekspresije.

Za evaluaciju performansi modela korišćene su sledeće metrike:

- **Accuracy** – procenat ispravno klasifikovanih ćelija,
- **Precision** – mera tačnosti predikcija za svaku klasu,
- **Macro Recall** – sposobnost modela da prepozna pripadnike određene klase,

- **Macro F1-score** – harmonijska sredina preciznosti i odziva, izračunata kao prosečna vrednost svih klasa.

Korišćena je *macro* varijanta metrika kako bi sve klase imale jednaku težinu prilikom evaluacije, bez obzira na broj ćelija koje sadrže.

Radi detaljnije analize rezultata prikazan je i izveštaj klasifikacije (classification report), kao i matrica konfuzije (confusion matrix), koja omogućava uvid u to koje tipove ćelija model najčešće međusobno meša.

Dobijeni rezultati ukazuju na sposobnost algoritama da prepoznaju obrasce genske ekspresije karakteristične za različite tipove ćelija ljudske jetre.

5.1 Random Forest

Random Forest klasifikator ostvario je visoku uspešnost na test skupu podataka. Dobijene vrednosti evaluacionih metrika iznosile su:

- **Accuracy:** 93.13%
- **Macro Recall:** 88.73%
- **Macro F1-score:** 90.99%

Visoka vrednost tačnosti ukazuje da je model uspešno klasifikovao najveći deo ćelija u odgovarajuće tipove. Pored toga, Macro F1-score veći od 0.90 pokazuje da model postiže dobar balans između preciznosti i odziva kroz različite klase.

Razlika između ukupne tačnosti (93.13%) i Macro Recall vrednosti (88.73%) ukazuje nam da model postiže nešto bolje rezultate na brojnijim klasama nego na retkim klasama. Ipak, ostvareni rezultati pokazuju da je Random Forest veoma efikasan za klasifikaciju tipova ćelija na osnovu podataka o genskoj ekspresiji.

Na osnovu dobijenih metrika može se zaključiti da Random Forest uspešno prepoznaje obrasce karakteristične za različite ćelijske populacije i predstavlja snažan osnovni model za analizu single-cell RNA-seq podataka.

5.2 Gradient Boosting

Gradient Boosting klasifikator ostvario je veoma visoke performanse u klasifikaciji tipova ćelija na osnovu genske ekspresije. Evaluacijom na test skupu dobijene su sledeće vrednosti metrika:

- **Accuracy:** 94.85%
- **Precision:** 95.41%
- **Macro Recall:** 94.76%
- **Macro F1-score:** 95.05%

Visoka vrednost svih korišćenih metrika pokazuje da je model uspešno naučio obrasce genske ekspresije karakteristične za različite tipove ćelija. Posebno je značajno što su vrednosti macro proseka približne ukupnoj tačnosti, što ukazuje da model postiže dobre rezultate ne samo na najzastupljenijim klasama, već i na klasama sa manjim brojem uzoraka.

5.3 XGBoost

XGBoost klasifikator ostvario je veoma visoke performanse u klasifikaciji tipova ćelija na osnovu profila genske ekspresije. Na test skupu dobijene su sledeće vrednosti evaluacionih metrika:

- **Accuracy:** 94.91%
- **Precision:** 95.45%
- **Macro Recall:** 93.70%
- **Macro F1-score:** 94.38%

Visoka vrednost tačnosti pokazuje da je XGBoost uspešno klasifikovao najveći broj ćelija u odgovarajuće kategorije. Takođe, visoke vrednosti precision i F1-score metrike ukazuju da model uspešno razlikuje različite tipove ćelija na osnovu njihovih obrazaca genske ekspresije.

Dobijeni rezultati potvrđuju da je XGBoost pogodan algoritam za klasifikaciju single-cell RNA-seq podataka, jer je sposoban da modeluje kompleksne nelinearne odnose između ekspresije gena i pripadnosti određenom tipu ćelije.

5.4 Logistička regresija

Logistic Regression model ostvario je veoma visoke performanse u klasifikaciji tipova ćelija na osnovu genske ekspresije. Evaluacijom na test skupu dobijene su sledeće vrednosti:

- Accuracy: 94.97%
- Precision: 95.89%
- Macro Recall: 94.28%
- Macro F1-score: 94.92%

Dobijene vrednosti metrika pokazuju da je logistička regresija uspešno naučila vezu između obrazaca genske ekspresije i pripadajućih tipova ćelija. Iako predstavlja jednostavniji model u odnosu na ensemble metode zasnovane na stablima odlučivanja, ostvario je veoma konkurentne rezultate.

Iako složeniji modeli poput Gradient Boosting i XGBoost mogu bolje da modeluju nelinearne odnose, logistička regresija je pokazala da i jednostavniji klasifikacioni pristup može postići veoma visoku preciznost na single-cell RNA-seq podacima.

5.5 Support Vector Machine (SVM)

SVM klasifikator ostvario je dobre performanse u klasifikaciji tipova ćelija na osnovu profila genske ekspresije. Evaluacijom modela na test skupu dobijene su sledeće vrednosti:

- **Accuracy:** 92.01%
- **Precision:** 94.94%
- **Macro Recall:** 89.49%
- **Macro F1-score:** 91.44%

Dobijeni rezultati pokazuju da SVM uspešno prepoznaje veliki broj obrazaca karakterističnih za različite tipove ćelija. Visoka vrednost precision metrike ukazuje da su predikcije modela uglavnom pouzdane, odnosno da, kada model dodeli određeni tip ćelije, ta odluka je u velikom broju slučajeva ispravna.

SVM je pokazao da je sposoban da izvrši uspešnu klasifikaciju visokodimenzionalnih single-cell RNA-seq podataka i predstavlja relevantan model za poređenje sa drugim klasifikacionim pristupima.

6 Poređenje modela klasifikacije

U okviru klasifikacije tipova ćelija ljudske jetre na osnovu single-cell RNA-seq podataka testirano je pet različitih algoritama mašinskog učenja: Random Forest, Gradient Boosting, XGBoost, Logistic Regression i Support Vector Machine (SVM).

Rezultati svih modela prikazani su u tabeli 1.

Tabela 1: Poređenje performansi klasifikacionih modela


Model	Accuracy	Precision	Macro Recall	Macro F1-score
Random Forest	0.9313	0.9500	0.8873	0.9099
Gradient Boosting	0.9485	0.9541	0.9476	0.9505
XGBoost	0.9491	0.9545	0.9370	0.9438
Logistic Regression	0.9497	0.9589	0.9428	0.9492
SVM	0.9201	0.9494	0.8949	0.9144

Na osnovu dobijenih rezultata može se zaključiti da su svi modeli uspešno izvršili klasifikaciju različitih tipova ćelija, pri čemu su svi ostvarili tačnost veću od 92%. Najslabije performanse ostvario je SVM model, dok su ostali modeli pokazali veoma slične i visoke rezultate.

Najveću ukupnu tačnost ostvario je **Logistic Regression model** sa vrednošću od 94.97%. Ovaj rezultat je posebno značajan jer je ostvaren korišćenjem relativno jednostavnog linearnog modela, što ukazuje da su obrasci genske ekspresije različitih tipova ćelija u velikoj meri međusobno razdvojeni.

Sa druge strane, **Gradient Boosting model** ostvario je najbolju vrednost Macro F1-score metrike (95.05%), što ukazuje na najbolji balans između preciznosti i odziva kroz različite klase. Zbog toga se Gradient Boosting može smatrati najrobustnijim modelom za ovaj problem, posebno imajući u vidu da se u klasifikaciji pojavljuju i manje zastupljene ćelijske populacije.

XGBoost je ostvario rezultate veoma bliske Gradient Boosting modelu, sa nešto većom tačnošću, ali nešto nižom Macro F1 vrednošću. Ovo pokazuje da dodatne optimizacije i regularizacija koje XGBoost koristi doprinose



Slika 2: Poređenje performansi klasifikacionih modela

dobroj generalizaciji, ali u ovom konkretnom skupu podataka nisu dovele do značajnog poboljšanja u odnosu na klasični Gradient Boosting.

Random Forest je takođe ostvario dobre rezultate, ali nešto slabije u poređenju sa boosting metodama. Njegova tačnost od 93.13% pokazuje da je sposoban da prepozna osnovne obrasce u genskoj ekspresiji, ali sekvencijalni pristup učenja kod boosting algoritama omogućava bolje hvatanje složenih odnosa između gena i tipova ćelija.

Na osnovu ukupne analize može se zaključiti da su **Gradient Boosting i Logistic Regression najuspešniji modeli za klasifikaciju tipova ćelija u ovom skupu podataka**. Gradient Boosting pokazuje najbolju sposobnost balansirane klasifikacije svih klasa, dok Logistic Regression pruža najvišu ukupnu tačnost uz jednostavniju strukturu modela.

Dobijeni rezultati potvrđuju da se podaci o genskoj ekspresiji dobijeni single-cell RNA-seq metodom mogu uspešno koristiti za automatsku identifikaciju ćelijskih populacija pomoću metoda mašinskog učenja.

7 Analiza značajnosti gena

Jedna od prednosti algoritama zasnovanih na stablima odlučivanja (Random Forest, Gradient Boosting i XGBoost) jeste mogućnost procene značaj-

nosti ulaznih atributa (*feature importance*). U kontekstu ovog projekta, svaki atribut predstavlja jedan gen, pa se na ovaj način može analizirati koji geni imaju najveći doprinos u razlikovanju različitih tipova ćelija.

Tokom treniranja modela izračunava se značajnost svakog gena na osnovu toga koliko često i koliko uspešno određeni atribut doprinosi podelama unutar stabala odlučivanja. Geni koji dovode do većeg smanjenja nečistoće čvorova (*impurity reduction*) dobijaju veće vrednosti značajnosti.

Nakon treniranja modela izdvojeni su geni sa najvećim vrednostima značajnosti. Ovi geni predstavljaju attribute koji su modelima bili najkorisniji za klasifikaciju tipova ćelija na osnovu njihovih profila genske ekspresije.

7.1 Random Forest

Rezultati analize značajnosti gena za Random Forest model prikazani su u tabeli 2.

Tabela 2: Najznačajniji geni prema Random Forest modelu

Gen	Importance
CD3D	0.008836
MZB1	0.008727
FCER1G	0.007472
TTR	0.007463
LYZ	0.007368
TYROBP	0.006866
TRAC	0.006653
APOA1	0.006566
APOH	0.006392
ORM2	0.006390

7.2 Gradient Boosting

Rezultati analize značajnosti gena za Gradient Boosting model prikazani su u tabeli 3.

Tabela 3: Najznačajniji geni prema Gradient Boosting modelu

Gen	Importance
CD3D	0.079660
LYZ	0.075144
TTR	0.066751
MZB1	0.058947
SCD	0.056132
MARCO	0.045335
FGFBP2	0.039258
AMBP	0.038419
CES1	0.023731
MGP	0.022928

7.3 XGBoost

Rezultati analize značajnosti gena za XGBoost model prikazani su u tabeli 4.

Tabela 4: Najznačajniji geni prema XGBoost modelu

Gen	Importance
CD3D	0.036075
TAT-AS1	0.029046
MZB1	0.025881
LYZ	0.024110
TTR	0.023372
FCN2	0.022952
MGP	0.021009
SCD	0.020857
LINC00844	0.019577
HBB	0.014616

Analiza značajnosti gena pruža dodatni uvid u karakteristike skupa podataka jer omogućava identifikaciju gena koji najviše doprinose razlikovanju ćelijskih populacija. Dobijeni rezultati mogu se dalje analizirati iz biološke

perspektive, poređenjem sa poznatim markerima karakterističnim za određene tipove ćelija.

Rezultati pokazuju da se među najznačajnijim genima u više modela pojavljuju geni **CD3D**, **MZB1**, **LYZ** i **TTR**. Njihovo prisustvo u vrhu rang-lista kod različitih algoritama ukazuje da predstavljaju stabilne i informativne markere za razlikovanje ćelijskih populacija.

Gen **CD3D** zauzima prvo mesto kod sva tri modela, što ukazuje da ima veliku diskriminativnu moć u procesu klasifikacije. Ovaj gen je poznat kao marker T-limfocita, pa njegova visoka značajnost ukazuje na važan doprinos razlikovanju imunskih ćelijskih populacija od ostalih tipova ćelija.

Gen **MZB1** se takođe nalazi među najvažnijim atributima kod sva tri modela. Povezan je sa plazma ćelijama i B-limfocitima, što ukazuje da modeli uspešno prepoznaju obrasce genske ekspresije karakteristične za ove ćelijske tipove.

Gen **LYZ** predstavlja marker mijeloidnih ćelija i makrofaga, dok je **TTR** karakterističan za hepatocite. Njihova visoka značajnost potvrđuje da modeli koriste biološki relevantne obrasce ekspresije za razlikovanje različitih populacija ćelija jetre.


Pored zajedničkih gena, pojedini modeli izdvajaju i specifične markere. Gradient Boosting i XGBoost ističu gene **SCD**, **MGP** i **MARCO**, dok XGBoost dodatno naglašava gene **FCN2**, **TAT-AS1** i **HBB**. Ove razlike proizlaze iz različitog načina na koji algoritmi formiraju modele i procenjuju doprinos pojedinačnih atributa.

Imajući u vidu sve ove rezultate, visoko poklapanje najznačajnijih gena između modela ukazuje na robustnost rezultata i potvrđuje da su identifikovani geni ključni za razlikovanje tipova ćelija u skupu podataka dobijenom primenom single-cell RNA-seq metode.

8 Vizualizacija rezultata primenom PCA

U cilju vizualizacije visokodimenzionalnih podataka primenjena je analiza glavnih komponenti (PCA), kojom je prostor od 2000 genskih atributa projektovan na dve dimenzije (Slika 3). Na taj način omogućeno je grafičko prikazivanje međusobnih odnosa između ćelija.

Na prikazanoj projekciji mogu se uočiti formirane grupe ćelija, što ukazuje na to da ćelije različitih tipova poseduju karakteristične obrasce genske ekspresije. Istovremeno, prisutna su i područja delimičnog preklapanja gru-



Slika 3: Projekcija ćelija

pa, što je očekivano zbog biološke srodnosti pojedinih ćelijskih populacija, posebno među različitim podtipovima hepatocita.

Dobijeni rezultat potvrđuje da podaci sadrže strukturu koja omogućava uspešnu klasifikaciju ćelijskih tipova, što je ranije potvrđeno visokim performansama klasifikacionih modela.

9 Analiza pravila pridruživanja

Pored klasifikacije ćelija u tipove, sprovedena je i analiza pravila pridruživanja sa ciljem identifikacije obrazaca zajedničke ekspresije gena. Za razliku od klasifikacionih modela, koji pokušavaju da predvide tip ćelije na osnovu ekspresije gena, pravila pridruživanja omogućavaju otkrivanje odnosa između samih gena, odnosno identifikaciju grupa gena koje se često eksprimiraju zajedno.

U kontekstu single-cell RNA-seq podataka, svaka ćelija može se posmatrati kao transakcija, dok geni predstavljaju stavke. Na taj način moguće

je primeniti algoritme za pronalaženje čestih skupova stavki i generisanje pravila pridruživanja.

Primenjena su naredna četiri pristupa:

- Apriori algoritam nad kompletnim skupom ćelija, uz generisanje pravila pridruživanja,
- FP-Growth algoritam na nivou pojedinačnih tipova ćelija, uz generisanje pravila pridruživanja,
- FP-Growth algoritam uz dodatak tipa ćelije (CellType) kao jedne od stavki,
- CHARM algoritam za generisanje zatvorenih čestih skupova stavki.

9.1 Apriori

Algoritam Apriori korišćen je za identifikaciju globalnih obrazaca koekspresije gena na kompletnom skupu podataka. Osnovna ideja algoritma zasniva se na pronalaženju čestih skupova stavki, odnosno grupa gena koje se zajedno pojavljuju u velikom broju ćelija.

Zbog velikog broja atributa izvršena je dodatna redukcija dimenzionalnosti. Za analizu je zadržano 500 gena sa najvećom varijansom, čime je smanjen broj mogućih kombinacija i omogućeno efikasnije izvršavanje algoritma.

Prilikom generisanja čestih skupova korišćeni su sledeći parametri:

- minimalna podrška ($min_support$) = 0.5,
- maksimalna veličina skupa stavki (max_len) = 3.

Visoka vrednost minimalne podrške omogućava izdvajanje samo najstabilnijih obrazaca prisutnih u velikom broju ćelija i sprečava nagli rast broja kandidata.

Primenom algoritma Apriori pronađeno je ukupno 2369 čestih skupova stavki.

9.1.1 Generisanje pravila pridruživanja

Nakon pronalaženja čestih skupova stavki generisana su pravila pridruživanja korišćenjem dve različite metrike: poverenja (*confidence*) i lift mere (*lift*).

Poverenje predstavlja verovatnoću da se telo pravila pojavi ukoliko je prisutna glava pravila. Za prag poverenja od 0.9 generisano je 1703 pravila pridruživanja.

Među pravilima sa najvećim poverenjem izdvajaju se:

- $FGL1 \rightarrow ORM1$,
- $AMBP \rightarrow APOC3$,
- $AMBP \rightarrow ORM1$,
- $AMBP \rightarrow MT2A$,
- $FGA \rightarrow APOC3$,
- $FGA \rightarrow ORM1$,
- $FGA \rightarrow MT2A$,
- $HLA-A \rightarrow TMSB10$.

Pored poverenja korišćena je i lift mera. Lift mera predstavlja odnos između stvarne učestalosti zajedničkog pojavljivanja gena i učestalosti koja bi se očekivala pod pretpostavkom njihove nezavisnosti. Vrednosti veće od 1 ukazuju na pozitivnu povezanost između gena.

Za prag lift mere od 1.2 dobijeno je 696 pravila pridruživanja. Među najzanimljivijim pravilima izdvajaju se:

- $FGL1 \rightarrow ORM1$,
- $AMBP \rightarrow APOC3$,
- $AMBP \rightarrow ORM1$,
- $HLA-A \rightarrow HLA-B$,
- $APOC3 \rightarrow FGA$.

Dobijeni rezultati ukazuju na postojanje grupa gena koje pokazuju stabilne obrasce zajedničke ekspresije u velikom broju ćelija. Takvi obrasci mogu predstavljati pokazatelje zajedničkih bioloških funkcija ili regulatornih mehanizama.

9.2 FP-Growth

Pored globalne analize, sprovedena je i analiza pravila pridruživanja na nivou pojedinačnih tipova ćelija. U tu svrhu korišćen je algoritam FP-Growth, koji predstavlja efikasniju alternativu algoritmu Apriori za rad sa većim skupovima podataka.

Za potrebe ove analize podaci o genskoj ekspresiji spojeni su sa tabelom koja sadrži oznake tipova ćelija. Nakon toga je za svaki ćelijski tip moguće izdvojiti odgovarajući podskup ćelija iz kompletnog skupa.

Prvobitno je planirano generisanje pravila za sve tipove ćelija korišćenjem jedinstvene iteracije po tipu ćelije. Međutim, zbog velikog broja mogućih kombinacija gena i veoma velikog broja čestih skupova stavki kod pojedinih ćelijskih tipova, vreme izvršavanja postalo je neprihvatljivo dugo. Kod nekih ćelijskih tipova broj pronađenih čestih skupova prelazio je desetine hiljada, što je značajno povećavalo memorijske i vremenske zahteve algoritma.

Zbog toga je analiza demonstrirana na pojedinačnim ćelijskim tipovima uz dodatno ograničavanje broja atributa na 800 najvarijabilnijih gena.

Za ćelijski tip *Inflammatory_Macrophage* korišćeni su parametri:

- minimalna podrška (*min_support*) = 0.2,
- minimalno poverenje (*min_confidence*) = 0.7.

Primenom algoritma FP-Growth za ove parametre pronađeno je 10151 čestih skupova stavki.

9.2.1 Generisanje pravila pridruživanja za ćelijski tip *Inflammatory_Macrophage*

Nakon pronalaženja čestih skupova stavki primenom FP-Growth algoritma generisana su pravila pridruživanja sa minimalnim poverenjem od 0.7. Za ćelijski tip *Inflammatory_Macrophage* dobijeno je ukupno 4462 pravila pridruživanja.

Radi lakše interpretacije rezultata, pravila su sortirana prema vrednosti poverenja. Najveće vrednosti ostvarila su pravila kod kojih se gen *C1QA* pojavljuje kao telo pravila, dok različite kombinacije gena uključuju gen *C1QB* u glavi pravila.

Neka od pravila sa najvećim vrednostima poverenja prikazana su u nastavku:

- *C1QB, NBEAL1* $\rightarrow$ *C1QA* (*confidence* = 0.995),
- *C1QB, HLA-DRB1* $\rightarrow$ *C1QA* (*confidence* = 0.991),
- *C1QB, ALDOA* $\rightarrow$ *C1QA* (*confidence* = 0.991),
- *C1QB, EIF3F* $\rightarrow$ *C1QA* (*confidence* = 0.989),
- *C1QB, FXYD5* $\rightarrow$ *C1QA* (*confidence* = 0.988).

Pored visokih vrednosti poverenja, navedena pravila poseduju i visoke vrednosti lift mere, koje se kreću između 1.74 i 1.78. Takve vrednosti ukazuju na to da je zajedničko pojavljivanje ovih gena značajno učestalije od onoga što bi se očekivalo pod pretpostavkom njihove međusobne nezavisnosti.

Posebno je zanimljivo što se gen *C1QB* pojavljuje u velikom broju pravila sa najvećim poverenjem, dok je gen *C1QA* gotovo uvek prisutan kao telo pravila. Ovo ukazuje na veoma snažnu povezanost između ekspresije ova dva gena unutar ćelija tipa *Inflammatory_Macrophage*.

Posmatrajući prvih dvadeset pravila može se uočiti da kombinacije gena *NBEAL1*, *HLA-DRB1*, *ALDOA*, *EIF3F*, *FXYD5*, *HLA-DPA1*, *HLA-DPB1*, *FCGRT*, *GRN* i drugih gena gotovo deterministički impliciraju prisustvo gena *C1QA*. Ovakvi obrasci ukazuju na postojanje stabilnih grupa koekspri-movanih gena karakterističnih za inflamatorne makrofage.

Za razliku od globalne analize sprovedene algoritmom Apriori, pravila dobijena FP-Growth algoritmom odražavaju specifične obrasce ekspresije unutar jedne ćelijske populacije. Zbog toga ona mogu pružiti detaljniji uvid u funkcionalne procese i regulatorne mehanizme karakteristične za ćelije tipa *Inflammatory_Macrophage*.

9.3 Pokušaj predikcije tipa ćelije pomoću pravila pridruživanja

Pored analize odnosa između gena, ispitan je i pristup u kome se tip ćelije posmatra kao dodatna stavka u transakciji. U tom slučaju moguće je generisati pravila oblika:

$$\text{GeneA, GeneB} \rightarrow \text{CellTypeX},$$

čije bi leve strane predstavljale skupove gena karakteristične za određeni tip ćelije.

Za realizaciju ovog pristupa izvršeno je one-hot kodiranje atributa *CellType*, nakon čega su oznake ćelijskih tipova uključene u skup stavki zajedno sa genima.

Međutim, ovaj pristup nije dao očekivane rezultate. Analiza distribucije pokazala je da čak i najzastupljeniji tipovi ćelija imaju podršku od približno 10–12%, dok većina tipova poseduje još manju zastupljenost. Kada se takve stavke kombinuju sa pojedinačnim genima, podrška odgovarajućih skupova veoma brzo pada ispod postavljenog praga.

Zbog toga, pri korišćenom pragu minimalne podrške od 0.1 nije pronađeno nijedno pravilo koje bi imalo oznaku tipa ćelije u posledici pravila.

Iako bi dodatno smanjenje minimalne podrške moglo dovesti do pronalazjenja takvih pravila, to bi istovremeno izazvalo značajan rast broja kandidata i vremena izvršavanja algoritma, zbog čega ovaj pristup nije dalje razvijan.

9.4 CHARM

Pored standardnih čestih skupova stavki analizirani su i zatvoreni česti skupovi stavki korišćenjem algoritma CHARM.

Zatvoren čest skup stavki predstavlja čest skup stavki za koji ne postoji nadskup sa istom podrškom. Ovakvi skupovi predstavljaju kompaktnu reprezentaciju svih čestih obrazaca jer eliminišu redundantne informacije i omogućavaju lakšu interpretaciju rezultata.

Analiza je sprovedena za ćelijski tip *Inflammatory_Macrophage*. Nakon filtriranja gena prema podršci i zadržavanja 100 najvarijabilnijih gena, podaci su transformisani u skup transakcija pogodan za rad algoritma CHARM.

Za prag minimalne podrške od 0.1 pronađeno je približno 7900 zatvorenih čestih skupova, što je predstavljalo prevelik broj obrazaca za efikasnu interpretaciju.

Zbog toga su analizirane veće vrednosti minimalne podrške. Rezultati su prikazani u tabeli 5.

Tabela 5: Broj zatvorenih čestih skupova za različite vrednosti minimalne podrške

MinSupport	Broj zatvorenih skupova
0.45	25
0.40	61
0.35	99

Rezultati pokazuju da vrednosti minimalne podrške između 0.35 i 0.40 predstavljaju dobar kompromis između broja pronađenih obrazaca i njihove interpretabilnosti.

Među najzastupljenijim genima koji se pojavljuju u zatvorenim čestim skupovima izdvajaju se geni NPM1, APOC1, PYCARD, GMFG i APOA1. Njihovo često prisustvo ukazuje na potencijalno značajnu ulogu u obrascima genske ekspresije karakterističnim za ćelije tipa *Inflammatory_Macrophage*.

Korišćenje zatvorenih čestih skupova omogućava sažetiji prikaz obrazaca zajedničke ekspresije gena u odnosu na standardne česte skupove stavki, uz očuvanje ključnih informacija o podršci i povezanosti između gena.

10 Zaključak

U ovom radu analizirani su single-cell RNA-seq podaci humanog tkiva jetre sa ciljem identifikacije i karakterizacije različitih tipova ćelija koje se tu mogu naći. Analiza je obuhvatila dve komplementarne celine: klasifikaciju ćelija u tipove primenom metoda mašinskog učenja i otkrivanje obrazaca zajedničke ekspresije gena korišćenjem pravila pridruživanja.

Rezultati klasifikacije pokazali su da posmatrani skup podataka poseduje izraženu strukturu koja omogućava uspešno razlikovanje ćelijskih populacija. Analiza glavnih komponenti dodatno je potvrdila prisustvo grupisanja ćelija prema obrascima genske ekspresije. Pored klasifikacije, analiza pravila pridruživanja omogućila je identifikaciju obrazaca zajedničke ekspresije gena.

Dobijeni rezultati pokazuju da kombinovanje klasifikacionih metoda i metoda za otkrivanje obrazaca omogućava sveobuhvatnu analizu single-cell RNA-seq podataka. Dok klasifikacioni modeli pružaju informacije o sposobnosti razlikovanja ćelijskih tipova, pravila pridruživanja omogućavaju uvid

u međusobne odnose gena i potencijalne biološke mehanizme koji stoje iza uočenih obrazaca ekspresije. Na taj način ostvaruje se potpunija interpretacija kompleksnih bioloških podataka u odnosu na interpretaciju koja bi bila dobijena korišćenjem samo jedne od ovih metoda.

Literatura

- [1] N. Aizarani et al., “A Human Liver Cell Atlas Reveals Heterogeneity and Epithelial Progenitors”, *Nature*, vol. 572, no. 7768, pp. 199–204, 2019. DOI: 10.1038/s41586-019-1373-2.
- [2] B. Hwang et al., “Single-cell RNA sequencing technologies and bioinformatics pipelines”, *Experimental & Molecular Medicine*, vol. 50, no. 8, pp. 1–14, 2018. DOI: 10.1038/s12276-018-0071-8.